

Формирование требований к архитектуре онтологии графа знаний по российскому законодательству: интеграция Akoma Ntoso, LKIF и ГОСТ Р 59798-2021 (BFO)

Архитектурная парадигма и фундаментальные вызовы формализации правовых знаний

Проектирование графов знаний (Knowledge Graphs, KG) в сфере юриспруденции представляет собой задачу исключительной семантической и алгоритмической сложности, обусловленную необходимостью точного, детерминированного отражения иерархических, темпоральных и причинно-следственных связей между нормами права. Информационные системы, оперирующие нормативно-правовыми актами, сталкиваются с фундаментальной проблемой: естественный язык права изобилует сложными перекрестными отсылками, неявными зависимостями и абстрактными концепциями, которые трудно поддаются алгоритмической обработке традиционными реляционными базами данных или системами полнотекстового поиска. В контексте разработки конвейера для российской базы знаний требуется создание многоуровневой архитектуры, способной преобразовывать неструктурированный текстовый массив в логически выверенную семантическую сеть, доступную для строгого машинного вывода (reasoning) и гибридного поиска (GraphRAG).

Основопологающая идея проектируемого конвейера базируется на интеграции трех независимых, но комплементарных технологических стандартов. Первым этапом выступает использование структурной логики стандарта Akoma Ntoso для изначальной разметки и подготовки текстов законов, в частности, на базе массивов данных корпуса RusLawOD. Вторым этапом является интеллектуальное извлечение сущностей из подготовленных текстов с их последующим семантическим маппингом на концептуальную модульную онтологию правовых знаний LKIF (Legal Knowledge Interchange Format). Завершающим, интегрирующим этапом конвейера служит строгое согласование полученной доменной архитектуры с национальным стандартом ГОСТ Р 59798-2021, регламентирующим применение Базисной формальной онтологии (BFO) в качестве онтологии высшего уровня (TLO). Подобный подход обеспечивает функциональную совместимость гетерогенных информационных систем, исключая концептуальные противоречия и создавая фундамент для семантической навигации по правовому пространству Российской Федерации.

Этап 1: Структурная нормализация и применение стандарта Akoma Ntoso

Любая семантическая надстройка требует надежного фундамента в виде машиночитаемой разметки исходных документов. Исторически развитие словарей правовой XML-разметки прошло четыре поколения: от простых типографских SGML-тегов первого поколения до паттерн-ориентированных схем четвертого поколения, обладающих сложными ограничениями (co-constraints) для локальных кастомизаций. Стандарт Akoma Ntoso, переданный в технический комитет OASIS LegalDocML и ратифицированный как официальный стандарт в 2018–2019 годах, представляет собой вершину эволюции структурной разметки юридических текстов. Данный формат обеспечивает глубокое разделение между контентом документа, его метаданными и слоем визуального представления, что критически важно для последующей графовой векторизации.

Интеграция модели FRBR в правовое пространство

Ключевым архитектурным преимуществом Akoma Ntoso является нативная реализация концептуальной библиографической модели FRBR (Functional Requirements for Bibliographic Records), которая решает сложнейшую задачу идентификации нормативного акта в условиях его постоянного изменения. Законодательство Российской Федерации характеризуется высокой динамикой внесения поправок (амендментов), что делает невозможным статичное хранение документов. Модель FRBR, инкапсулированная в метаданных Akoma Ntoso (в блоке <identification>), внедряет четырехуровневую иерархию абстракции для каждого документа:

- **FRBRWork (Произведение):** Идентифицирует нормативный акт как абстрактную интеллектуальную сущность (например, «Гражданский кодекс Российской Федерации»). Этот уровень абстрагирован от конкретных слов и языка; он символизирует концепт самого закона.
- **FRBRExpression (Выражение):** Отражает конкретную версию или редакцию акта на определенную временную шкалу (например, «Гражданский кодекс в редакции от 15 марта 2023 года на русском языке»). Одно «Произведение» может иметь множество «Выражений», отражающих его историческую эволюцию.
- **FRBRManifestation (Воплощение):** Определяет формат кодирования данных конкретного выражения (например, XML-файл стандарта Akoma Ntoso, подписанный PDF-документ или HTML-страница).
- **FRBRItem (Экземпляр):** Указывает на физическое или сетевое местоположение файла (например, конкретный URL-адрес на сервере системы хранения).

Эта иерархия позволяет графу знаний дифференцировать семантические запросы. Если пользователь запрашивает «текущий статус статьи 44-ФЗ», система маршрутизирует запрос через уровень FRBRWork к наиболее актуальному узлу FRBRExpression, игнорируя

устаревшие редакции, тем самым обеспечивая детерминированность выдачи.

Адаптация корпуса RusLawOD к требованиям LegalDocML

Для реализации конвейера на данных российского права оптимальным исходным массивом служит корпус RusLawOD (Russian Legislative Corpus). Данный открытый ресурс агрегирует беспрецедентный объем информации: все несекретные федеральные законы и нормативные акты Российской Федерации, охватывающие период с 1991 года по настоящее время.

Однако текущая архитектура RusLawOD не является полностью совместимой со стандартом Akoma Ntoso, так как корпус использует лишь высокоуровневые теги (например, <act>), оставляя тело закона слабоструктурированным. Для полноценной работы конвейера графа знаний требуется разработка промежуточного слоя XSLT-трансформации. Разделы, главы, статьи и пункты должны быть инкапсулированы в соответствующие XML-элементы с присвоением глобально уникальных идентификаторов (URI/IRI). Учитывая объем корпуса, необходимо разработать прототип XSLT-процессора и провести бенчмарк на репрезентативной выборке для оценки вычислительной сложности парсинга сотен тысяч документов и обработки аномалий (таких как отсутствие нумерации). Подобная атомизация текста позволяет в дальнейшем генерировать векторные представления не для всего документа целиком, а для конкретных структурных компонентов, повышая точность поиска.

Этап 2: Интеллектуальная экстракция сущностей (NER) и деонтический маппинг

Переход от размеченного XML-дерева к многомерному графу знаний невозможен без точной идентификации правовых сущностей внутри текста. Технологической основой для слоя экстракции выступает архитектура RuBERT, усиленная условными случайными полями (CRF), обученная на специализированных датасетах (например, RuLegalNER), способная выявлять субъекты, объекты, штрафные санкции и сроки.

Критическим вызовом на данном этапе является извлечение и маппинг деонтических операторов из естественного русского языка в концепты онтологии LKIF. Русский юридический язык обладает широким спектром прескриптивных лексем, зависящих от контекста. Русский язык, в отличие от германских, не имеет развитой морфологической системы модальных глаголов, поэтому деонтическая модальность в нем выражается через специальный репертуар предикативных выражений (таких как «надо», «нужно», «можно», «нельзя», «запрещено» и «должен»). Алгоритм маппинга должен базироваться на строгой формальной таблице соответствий, учитывающей отрицания:

- **Ikif:Obligation (Обязанность):** Извлекается из лексем «обязан», «должен», «надлежит», «необходимо», «возлагается обязанность».
- **Ikif:Permission (Дозволение/Право):** Извлекается из лексем «вправе», «может», «имеет право», «допускается».

- **Ikif:Prohibition (Запрет):** Формируется либо прямыми лексемами («запрещается», «нельзя», «не допускается»), либо через синтаксический анализ отрицательных частиц при дозволяющих глаголах («не вправе», «не может»).

Анализ отрицаний на этапе парсинга (NER) критически важен, так как инверсия контекста (например, превращение Permission в Prohibition) определяет корректность логического вывода в графе.

Этап 3: Семантическое моделирование: LKIF и интеграция слоя RusLegalCore

Legal Knowledge Interchange Format (LKIF) представляет собой ядровую онтологию правовых понятий, обеспечивающую перевод извлеченных текстов в аксиомы дескриптивной логики (OWL-DL). Однако LKIF изначально разрабатывалась для европейской правовой традиции и не покрывает уникальные аспекты российской правовой системы.

Для решения этой проблемы в архитектуру вводится промежуточный онтологический слой **RusLegalCore**, который наследует базовые модули LKIF (norm, role, action), но расширяет их для отражения российской специфики:

1. **Иерархия нормативно-правовых актов:** Введение строгой субординации источников права в порядке убывания их юридической силы: Конституция РФ → федеральные конституционные законы → федеральные законы (включая кодексы) → указы Президента РФ → постановления и распоряжения Правительства РФ → нормативные акты уполномоченных государственных органов (ведомственные акты) → региональное законодательство.
2. **Федеративное устройство:** Моделирование разграничения предметов ведения между Российской Федерацией и ее субъектами.
3. **Интеграция с судебной практикой:** Создание узлов для правовых позиций (решения Конституционного Суда РФ, Пленумы Верховного Суда РФ), связывающих абстрактную норму с ее толкованием в правоприменении.

Механизм разрешения правовых коллизий

Российское право неизбежно содержит коллизии между нормативными актами. Конвейер графа знаний должен обладать встроенным механизмом разрешения противоречий. В рамках онтологии RusLegalCore и логики графа необходимо реализовать ребра типа SUPERSEDES (отменяет/замещает) и алгоритмическую имплементацию трех мета-правил (правовых максим):

- **Lex superior (приоритет нормы высшей силы):** Если нормы противоречат друг другу, граф отдает приоритет норме из акта, стоящего выше в иерархии (например, ФЗ превалирует над Приказом министерства).
- **Lex specialis (приоритет специальной нормы):** При конфликте общей и

специальной нормы равной юридической силы применяется специальная (например, нормы ФЗ о закупках превалируют над общими положениями ГК РФ в рамках контрактной системы). Классическое понимание этого правила означает, что более конкретная норма, регулирующая отношения типа "род-вид", имеет приоритет над более абстрактной нормой. Алгоритмизация подобных максим (включая *lex superior* и *lex posterior*) позволяет эффективно разрешать нормативные коллизии внутри графа.

- **Lex posterior (приоритет новой нормы):** При прочих равных условиях приоритет отдается норме, принятой позднее.

Этап 4: Выравнивание архитектуры верхнего уровня с ГОСТ Р 59798-2021 (BFO)

Для обеспечения подлинной интероперабельности разнородных государственных информационных систем национальный стандарт Российской Федерации ГОСТ Р 59798-2021 диктует применение Базисной формальной онтологии (Basic Formal Ontology, BFO) в качестве онтологии высшего уровня (TLO). BFO жестко разделяет сущее на Континуанты (сохраняющие идентичность во времени) и Оккуренты (разворачивающиеся во времени).

Ошибочный маппинг доменной правовой онтологии на BFO может привести к логическим коллизиям. Спроектированная архитектура соответствий для российского права выглядит следующим образом:

Категория доменной онтологии (LKIF/RusLegalCore)	Целевой класс TLO (BFO 2020 по ГОСТ Р 59798-2021)	Архитектурное и логическое обоснование
Physical_Concept, Субъекты права (Физ./Юр. лица)	bfo:Independent Continuant	Независимые сущности, сохраняющие тождество во времени.
Legal_Role (Поставщик, Судья, Истец)	bfo:Role (потомок Dependent Continuant)	Роль актуализируется только в специфических условиях и не существует без независимого носителя.

Текст закона (XML-манифестация Akoma Ntoso)	bfo:Generically Dependent Continuant (в частности, Information Content Entity)	Закон как информационный артефакт (текст) может быть скопирован на разные носители, сохраняя свою идеальную идентичность.
Нормативная модальность (Обязанность, Право)	bfo:Generically Dependent Continuant (в частности, Directive Information Entity)	Регулятивный конструкт, определяющий прескриптивное содержание закона.
Правовые процедуры, Акт принятия/отмены нормы	bfo:Process (потомок bfo:Occurrent)	Процедуры принятия закона, судебные заседания и факты внесения поправок разворачиваются во времени как события.

Формализация на Common Logic (CL)

ГОСТ Р 59798-2021 требует представления BFO не только в OWL 2, но и в форматах семейства Common Logic (CLIF или FOL). Использование CL критически важно для правовой онтологии, так как дескриптивная логика (OWL) имеет ограничения в выразительности сложных темпоральных интервалов и мереотопологических отношений (сущностных связей часть-целое). Конвейер должен предусматривать разработку профиля CL для строгой математической аксиоматизации периодов действия законов (например, обратной силы закона).

Этап 5: Архитектура гибридного поиска GraphRAG на базе онтологии

Спроектированные онтологические конструкции должны быть имплементированы в высокопроизводительную среду, способную работать с парадигмой Ontology-Driven GraphRAG. Базовой концепцией хранилища (на базе графово-векторных СУБД, таких как FalkorDB) становится семантически осознанная сегментация и модель агрегации темпоральных версий (CTV). При внесении поправок система переиспользует связи неизменных статей, создавая новые узлы только для обновленных фрагментов.

Векторные представления (эмбединги) сохраняются в свойствах узлов графа, позволяя

объединять топологические фильтры Cypher (отсекающие недействующие версии) и алгоритмы поиска ближайших соседей (HNSW) в единой транзакции.

Для обеспечения масштабируемости (Scalability) архитектура должна сопровождаться строгим разделом Performance Requirements (SLA), определяющим:

- Необходимые объемы RAM/VRAM для кэширования графовых индексов 300+ тысяч документов.
- Допустимое время отклика для многосоставных запросов (с учетом обхода графа коллизий).
- Требования к сжатию контекста (TF-IDF, YAKE) для снижения нагрузки на генеративные LLM.

Результирующие требования к проектированию конвейера базы знаний

Синтез проанализированных стандартов позволяет сформулировать инженерные требования для реализации конвейера российского графа правовых знаний:

1. **Подсистема препроцессинга:** Необходима глубокая структурная разметка корпуса RusLawOD в стандарт Akoma Ntoso (модель FRBR) посредством масштабируемых XSLT-процессоров.
2. **Слой экстракции (NER) и деонтический маппинг:** Использование дообученных моделей (RuBERT-CRF) с внедрением формальной таблицы обработки контекста и отрицаний для корректной трансляции русскоязычных прескриптивных глаголов в логику LKIF (Obligation, Permission, Prohibition).
3. **Локализация онтологии (RusLegalCore):** Разработка промежуточного слоя над LKIF, явно описывающего российскую иерархию актов, федеративное устройство и прецедентное толкование, с интеграцией графовых механизмов разрешения коллизий (lex specialis, lex posterior, lex superior).
4. **Соблюдение ГОСТ Р 59798-2021:** Строгий маппинг правовых конструкторов на дихотомию Континуантов/Оккурентов BFO 2020 с обязательным применением спецификаций OWL 2 и Common Logic (CL) для выражения сложных аксиом времени и структуры.
5. **Экспериментальная валидация и SLA:** Проведение обязательного пилотного тестирования полного цикла конвейера на подмножестве не менее 1000 документов корпуса RusLawOD для выявления аномалий парсинга, а также разработка метрик производительности гибридного поиска (GraphRAG).

Заключение

Масштабная цифровизация российской правовой системы немыслима без создания глубоко структурированной, семантически прозрачной базы знаний. Архитектурный конвейер, объединяющий разметку Akoma Ntoso, дополненную онтологию LKIF

(RusLegalCore) и национальный стандарт ГОСТ Р 59798-2021 (BFO), трансформирует подверженный интерпретациям массив текстов в детерминированную навигационную сеть. Внедрение гибридного поиска GraphRAG с учетом правовых коллизий, темпоральности и строгих лингвистических правил позволит системе осуществлять точный логический вывод, создавая суверенную и масштабируемую экосистему правовых знаний Российской Федерации.